Curso: Tecnologia em Data Science, Big Data, BI & Data Engineering

Projeto: CHALLENGE (012024)

Turmas do 1o ano: 1TSCPV

Sprint 3

DataStorm

Ana Beatriz Azevedo, RM557420
Heloiza Oliveira, RM558881
Isabelle Nahas, RM557405
Matheus Madrid, RM555799
Sara Sitta, RM555113

DISCIPLINA: ARCHITECTURE ANALYTICS & NOSQL

Professores: Leandro Romualdo da Silva, Milton Goya

Documentação do Pipeline de Dados


Visão Geral

Este documento descreve o pipeline de dados implementado para ingestão, transformação, armazenamento e consumo de dados climáticos coletados de uma API, usando Apache Airflow no Google Cloud Composer, Google Cloud Storage como Data Lake, e BigQuery para armazenamento e transformação dos dados. O pipeline é composto por três DAGs principais, cada uma responsável por uma etapa específica do fluxo de dados.

1. Ferramenta de ETL/Ingestão

Para atender aos requisitos de coleta, ingestão, armazenamento, transformação e orquestração, foram utilizados Apache Airflow no Google Cloud Composer para orquestração, Google Cloud Storage para armazenamento temporário, e BigQuery para transformação e armazenamento dos dados estruturados.


Arquitetura atualizada:




Link: https://miro.com/app/board/uXjVKmDD4gU=/?share link id=695605839813

https://miro.com/welcomeonboard/dnRiaHI0VEJPOW9KdW84ZUNCanJBTTF4dkpXTkQ2M3ZR NkFOend0cmxsRWNtZGlKNm8yYUtlWDBHeXF1Qk5CVHwzNDU4NzY0NTc3MzU0NTcyMjQ0fDI =?share_link_id=512033522479


Parte1(ArquiteturaAtt)




Parte2(ArqAtt)




Google Cloud Composer




Apache Airflow:



CloudStorage – Landing Zone



Bigguery GCP



1.1 Coleta e Ingestão de Dados para o Data Lake e BigQuery (DAG: weather_data_pipeline_dag)

- Nome da DAG: weather_data_pipeline_dag
- Ferramenta Utilizada: Apache Airflow com Google Cloud Composer para orquestração; Google Cloud Storage para armazenamento dos dados e BigQuery para estruturação do Lake
- Processo:
 - Coleta de Dados: A DAG coleta dados climáticos da API do OpenWeatherMap em intervalos regulares (a cada 1 hora).
 - Armazenamento Temporário: Os dados coletados são salvos no Google Cloud Storage, que atua como o Data Lake.
 - Carga para BigQuery: Após salvar no Cloud Storage, os dados são carregados na camada RAW do BigQuery, utilizando operadores específicos do Airflow para transferência de arquivos do Cloud Storage para o BigQuery.

```
form airflow import DNG
   from airflow.providers.google.cloud.transfers.goz_to_biguery import GCSTOBigUeryOperator
   from airflow.providers.google.cloud.transfers.goz_to_biguery import GCSTOBigUeryOperator
   from airflow.providers.google.cloud.transfers.goz_to_local import GCSTOBigUeryOperator
   from airflow.urproviders.google.cloud.transfers.goz_to_local import GCSTOBigUeryOperator
   import pands as pd
   import time
   import requests
   import requests
   import requests
   import import goteter dados das subprefeituras e salvar em formato adequado para o BigQuery
   def collect_weather_data("Namargs):
    # Runker por CSV das subprefeituras e salvar em formato adequado para o BigQuery
   def collect_weather_data("Namargs):
    # Bakker o CSV das subprefeituras e salvar em formato adequado para o BigQuery
   def collect_weather_data("Namargs):
    # Bakker o CSV das subprefeituras e subprefeituras.sp.cosv, sep-i; header-e)
   subprefeituras.columns = subprefeituras.sp.cosv, sep-i; header-e)
   subprefeituras.columns = subprefeituras.polema.str.strip().str.lower()

### APT_KEY = "-" # Substitus pals sus chave da API

### APT_KEY = "-" # Substitus pals sus chave da API


### BASE_UBL = https://history.openmenthermap.org/data/2.5/history/city'


### It = round(row('latitude'), 2)

### It = round(r
```


Arquivo anexado - weather_data_pipeline_dag.py

weather data pipeline dag. DAG no Airflow






LANDING ZONE no Google Cloud Storage



Camada RAW.WEATHER




1.2 Estruturação e Preparação dos Dados para a Camada Estruturada (DAG: etl_raw_to_trusted_weather)


- Nome da DAG: etl_raw_to_trusted_weather
- Ferramenta Utilizada: Apache Airflow com Google Cloud Composer para orquestração; Google Cloud Storage para armazenamento dos dados e BigQuery para transformação dos dados.
- Processo:
 - Esta DAG transforma e estrutura os dados movendo-os da camada RAW para a camada TRUSTED no BigQuery.
 - Transformações Incluídas:
 - Ajuste de precisão de latitude e longitude para garantir a consistência entre os conjuntos de dados.
 - Conversão de CEP de string para inteiro, removendo caracteres indesejados.
 - Criação de views para padronizar os nomes das colunas para o padrão de Data Lake (letra maiúscula, sem underscores).


Task 4 da DAG weather_data_pipeline_dag

```
» DAG weather_data_pipeline
 ⚠ Details 📲 Graph 🖃 Gantt 🕠 Code 🚡 Audit Log 📓 Run Duration 🛅 Calendar
 Parsed at: 2024-09-09, 02:07:40 UTC
                  task_id='collect_weather_data',
                 python_callable=collect_weather_data,
                 provide_context=True,
     99
    100
    101
             # Task 3: Enviar JSON para o Cloud Storage na pasta especificada
    102
             upload to gcs = LocalFilesystemToGCSOperator(
    103
              task_id='upload_to_gcs',
src='/tmp/historical_weather_data.json',
    104
    105
                 dst='LANDING_ZONE_WEATHER/historical_weather_data.json',
                bucket='us-central1-datastorm-prod-us-a4c8a156-landingzone',
    107
    108
    109
              load_to_bigquery = GCSToBigQueryOperator(
task_id='load_to_bigquery',
    110
                  bucket='us-central1-datastorm-prod-us-a4c8a156-landingzone',
                  source_objects=['LANDING_ZONE_WEATHER/historical_weather_data.json'],
destination_project_dataset_table='elated-drive-432523-54:RAW.WEATHER', # Substitua pelo seu projeto e dataset
    113
                  source_format='NEWLINE_DELIMITED_JSON',
    116
                  write_disposition='WRITE_APPEND',
    118
              # Definir a seauência das tasks
              download_csv >> collect_data_task >> upload_to_gcs >> load_to_bigquery
    120
```


Camada RAW.WEATHER








Tasks da DAG



Dag anexada no zip etl_raw_to_trusted_weather.py


CAMADA TRUSTED




1.3 Refinamento e Enriquecimento dos Dados (DAG: etl_trusted_to_refined_weather)

- Nome da DAG: etl trusted to refined weather
- **Ferramenta Utilizada:** Apache Airflow com Google Cloud Composer para orquestração; BigQuery para refinamento e enriquecimento dos dados.
- Processo:
 - A última DAG move os dados da camada TRUSTED para a camada REFINED no BigQuery.
 - Refinamento Inclui:
 - Criação de tabelas finais na camada REFINED.
 - Adição de descrições das colunas para melhorar a documentação e a compreensão dos dados.
 - Junção de dados climáticos com informações de subprefeituras para fornecer um conjunto de dados enriquecido.


DAG etl_trusted_to_refined_weather no Airflow






Arquivo anexado no zip etl_trusted_to_refined_weather.py

CAMADA REFINED com a tabela WEATHER final com as Descrições



2. Implantação de um banco de dados NoSQL. O grupo deve escolher um banco de dados NoSQL e adicionar na sua solução em qualquer fase do pipeline de dados. Pesquise, questione o professor da disciplina e veja o que mais se adequa ao seu cenário e faça a implantação.

Todas as imagens anexadas no zip



```
0
mongosh mongodb://localhost:27017/?directConnection=true&serverSelectionTimeoutMS=2000
                                                                                                                                                          rid: 1, productid: 1, nota:10, review: "excelente produto"),
rid: 2, productid: 1, nota:10, review: "Sem"),
rid: 3, productid: 1, nota:10, review: "Sem"),
rid: 3, productid: 1, nota:10, review: "Custo Demericio bom"),
rid: 5, productid: 10, nota:10, review: "Custo Demericio bom"),
rid: 6, productid: 10, nota:10, review: "Custo Demericio bom"),
rid: 7, productid: 10, nota:10, review: "Custo Demericio excelente"),
rid: 8, productid: 3, nota:10, review: "nota mal"),
rid: 8, productid: 3, nota:10, review: "mutio bom , ganhou um cliente"),
rid: 10, productid: 8, nota:0, review: "mutio bom , ganhou um cliente"),
rid: 10, productid: 8, nota:0, review: "mutio bom , ganhou um cliente"),
rid: 10, productid: 8, nota:0, review: "mutio bom , ganhou um cliente"),
                of the state of th
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        ヘ に 48 20:48
15/08/2024
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         O
```

^ 딮 ds 20:48

🗎 🦁 🧿 🩋 🗷 🖭 👣

```
O
mongosh mongodb://localhost:27017/?directConnection=true&serverSelectionTimeoutMS=2000
  icrosoft Windows [Version 10.0.19045.4651]
c) Microsoft Corporation. All rights reserved.
    help improve our products, anonymous usage data is collected and sent to MongoOB periodically (https://www.mongodb.com/legal/privacy-policy).
u can opt-out by running the disableTelemetry() command.
     ---
The server generated these startup warnings when booting
2024-08-15723:22:35.362+00:00: Using the XFS filesystem is strongly recommended with the WiredTiger storage engine. See http://dochub.mongodb.org/core/prodnotes-file
     tem
2024-08-15T23:22:36.455+00:00: Access control is not enabled for the database. Read and write access to data and configuration is unrestricted
2024-08-15T23:22:36.455+00:00: /sys/kernel/mm/transparent_hugepage/enabled is 'always'. We suggest setting it to 'never' in this binary version
2024-08-15T23:22:36.455+00:00: vm.am._map_count is too low
    st> use livemongodb
itched to db livemongodb
vemongodb> db.createCollection("users")
       mongodb> db.createco...
: 1 }
mongodb> db.createCollection("product")
           1 }
ngodb> db.createCollection("orders")
                db> db.createCollection("reviews")
                                                                                                                                                                                                                                                                         ヘロ 4s 20:47
15/08/2024
Administrator Windows PowerShell
Windows PowerShell
Copyright (C) Microsoft Corporation. All rights reserved.
     the new cross-platform PowerShell https://aka.ms/pscore6
                 c: Pull complete
Scied27a97526648Faee269e6b5c6b1c7b3d9de3ddd8s1d5097a0881e15576bbb4
lloaded newer image for mongo:latest
Diarry/mongo:latest
Llabsflap> docker run --name mongodb-container -d -p 27017:27017 mongo:latest
Llabsflap> docker run --name mongodb-ba9la7273d3ebe600
 a m 🖁 🧿 🙋 🗷 🕾 😘
                                                                                                                                                                                                                                                                          ヘ 口 ds 15/08/2024
```

3. Documentação e Evidências

Todas as etapas foram capturadas e documentadas para comprovar o funcionamento do pipeline.

Conclusão

O pipeline foi implementado utilizando Google Cloud Composer com Apache Airflow para orquestrar a coleta, transformação e carga de dados climáticos. As três DAGs (weather_data_pipeline_dag, etl_raw_to_trusted_weather, e

etl_trusted_to_refined_weather) garantem que os dados sejam coletados, transformados e enriquecidos de forma escalável e automatizada. As descrições dos campos na camada REFINED ajudam a documentar e entender o conjunto de dados final para consumo analítico.

Este documento serve como uma referência completa das ferramentas e processos utilizados, garantindo uma visão clara do fluxo de dados desde a coleta até o refinamento final para uso analítico.