Curso: Tecnologia em Data Science, Big Data, BI & Data Engineering

Projeto: CHALLENGE (012024)

Turmas do 1o ano: 1TSCPV

Sprint 3

#### **DataStorm**

Ana Beatriz Azevedo, RM557420 Heloiza Oliveira, RM558881 Isabelle Nahas, RM557405 Matheus Madrid, RM555799 Sara Sitta, RM555113

**DISCIPLINA: BIG DATA ARCHITECTURE & DATA INTEGRATION** 

Professores: Rogerio Mariana Galazi, Milton Goya

#### Documentação do Pipeline de Dados


#### Visão Geral

Este documento descreve o pipeline de dados implementado para ingestão, transformação, armazenamento e consumo de dados climáticos coletados de uma API, usando Apache Airflow no Google Cloud Composer, Google Cloud Storage como Data Lake, e BigQuery para armazenamento e transformação dos dados. O pipeline é composto por três DAGs principais, cada uma responsável por uma etapa específica do fluxo de dados.

#### 1. Ferramenta de ETL/Ingestão


Para atender aos requisitos de coleta, ingestão, armazenamento, transformação e orquestração, foram utilizados Apache Airflow no Google Cloud Composer para orquestração, Google Cloud Storage para armazenamento temporário, e BigQuery para transformação e armazenamento dos dados estruturados.

#### Arquitetura atualizada:




Link: <a href="https://miro.com/app/board/uXjVKmDD4gU=/?share">https://miro.com/app/board/uXjVKmDD4gU=/?share</a> link id=695605839813


#### Google Cloud Composer




#### Apache Airflow:



#### CloudStorage - Landing Zone



#### **Bigquery GCP**




# 1.1 Coleta e Ingestão de Dados para o Data Lake e BigQuery (DAG: weather\_data\_pipeline\_dag)


- Nome da DAG: weather\_data\_pipeline\_dag
- Ferramenta Utilizada: Apache Airflow com Google Cloud Composer para orquestração; Google Cloud Storage para armazenamento dos dados e BigQuery para estruturação do Lake
- Processo:
  - Coleta de Dados: A DAG coleta dados climáticos da API do OpenWeatherMap em intervalos regulares (a cada 1 hora).
  - Armazenamento Temporário: Os dados coletados são salvos no Google Cloud Storage, que atua como o Data Lake.
  - Carga para BigQuery: Após salvar no Cloud Storage, os dados são carregados na camada RAW do BigQuery, utilizando operadores específicos do Airflow para transferência de arquivos do Cloud Storage para o BigQuery.

```
from airflow import DAG
from airflow.operators.python import PythonOperator
 from airflow.providers.google.cloud.transfers.local_to_gcs import LocalFilesystemToGCSOperator from airflow.providers.google.cloud.transfers.gcs_to_bigquery import GCSToBigQueryOperator from airflow.providers.google.cloud.transfers.gcs_to_local import GCSToLocalFilesystemOperator
 from airflow.utils.dates import days ago
import requests import time
from datetime import datetime
# Função para coletar dados das subprefeituras e salvar em formato adequado para o BigQuery def collect_weather_data(**kwargs):
        # Baixar o CSV das subprefeituras diretamente do Google Cloud Storage
subprefeituras = pd.read_csv('/tmp/subprefeituras-sp.csv', sep=';', header=0)
subprefeituras.columns = subprefeituras.columns.str.strip().str.lower()
        API KEY = '--' # Substitua pela sua chave da API
BASE_URL = 'https://history.openweathermap.org/data/2.5/history/city'
         for index, row in subprefeituras.iterrows():
           lat = round(row['latitude'], 2)
lon = round(row['longitude'], 2)
subprefeitura nome = row['subprefeitura']
url = f"{BASE_URL}?lat={lat:.2f}&lon={lon:.2f}&appid={API_KEY}"
                response = requests.get(url)
                         data = response.json()
if 'list' in data:
                                for entry in data['list']:
    result = {
                                                'subprefeitura': subprefeitura_nome,
'latitude': lat,
'longitude': lon,
                                                  'timestamp': datetime.utcfromtimestamp(entry['dt']).isoformat(), # Converter para timestamp ISO
                                                 timestamp: datetime.utcfromtimestamp(entry,
'temprature': entry['main'].get('temp'),
'feels_like': entry['main'].get('feels_like'),
'pressure': entry['main'].get('pressure'),
'humidity': entry['main'].get('humidity'),
'temp_min': entry['main'].get('temp_min'),
'temp_max': entry['min'].get('temp_max'),
'wind_speed': entry['wind'].get('speed'),
'wind_speed': entry['wind'].get('speed'),
```


Arquivo anexado - weather\_data\_pipeline\_dag.py



LANDING ZONE no Google Cloud Storage



#### Camada RAW.WEATHER





# 1.2 Estruturação e Preparação dos Dados para a Camada Estruturada (DAG: etl\_raw\_to\_trusted\_weather)


- Nome da DAG: etl\_raw\_to\_trusted\_weather
- Ferramenta Utilizada: Apache Airflow com Google Cloud Composer para orquestração; Google Cloud Storage para armazenamento dos dados e BigQuery para transformação dos dados.
- Processo:
  - Esta DAG transforma e estrutura os dados movendo-os da camada RAW para a camada TRUSTED no BigQuery.
  - Transformações Incluídas:
    - Ajuste de precisão de latitude e longitude para garantir a consistência entre os conjuntos de dados.
    - Conversão de CEP de string para inteiro, removendo caracteres indesejados.
    - Criação de views para padronizar os nomes das colunas para o padrão de Data Lake (letra maiúscula, sem underscores).

```
» DAG weather_data_pipeline
 ⚠ Details 📲 Graph 🖃 Gantt 🕠 Code 🚡 Audit Log 📓 Run Duration 🛅 Calendar
 Parsed at: 2024-09-09, 02:07:40 UTC
                  task_id='collect_weather_data',
                 python_callable=collect_weather_data,
                 provide_context=True,
     99
    100
    101
             # Task 3: Enviar JSON para o Cloud Storage na pasta especificada
    102
             upload to gcs = LocalFilesystemToGCSOperator(
    103
              task_id='upload_to_gcs',
src='/tmp/historical_weather_data.json',
    104
    105
                 dst='LANDING_ZONE_WEATHER/historical_weather_data.json',
                bucket='us-central1-datastorm-prod-us-a4c8a156-landingzone',
    107
    108
    109
              load_to_bigquery = GCSToBigQueryOperator(
task_id='load_to_bigquery',
    110
                  bucket='us-central1-datastorm-prod-us-a4c8a156-landingzone',
                  source_objects=['LANDING_ZONE_WEATHER/historical_weather_data.json'],
destination_project_dataset_table='elated-drive-432523-54:RAW.WEATHER', # Substitua pelo seu projeto e dataset
    113
                  source_format='NEWLINE_DELIMITED_JSON',
    116
                  write_disposition='WRITE_APPEND',
    118
              # Definir a seauência das tasks
              download_csv >> collect_data_task >> upload_to_gcs >> load_to_bigquery
    120
```


#### Camada RAW.WEATHER








#### Tasks da DAG



Dag anexada no zip etl\_raw\_to\_trusted\_weather.py


CAMADA TRUSTED




#### 1.3 Refinamento e Enriquecimento dos Dados (DAG: etl\_trusted\_to\_refined\_weather)

- Nome da DAG: etl trusted to refined weather
- **Ferramenta Utilizada:** Apache Airflow com Google Cloud Composer para orquestração; BigQuery para refinamento e enriquecimento dos dados.
- Processo:
  - A última DAG move os dados da camada TRUSTED para a camada REFINED no BigQuery.
  - Refinamento Inclui:
    - Criação de tabelas finais na camada REFINED.
    - Adição de descrições das colunas para melhorar a documentação e a compreensão dos dados.
    - Junção de dados climáticos com informações de subprefeituras para fornecer um conjunto de dados enriquecido.


#### DAG etl\_trusted\_to\_refined\_weather no Airflow





Arquivo anexado no zip etl\_trusted\_to\_refined\_weather.py

#### CAMADA REFINED com a tabela WEATHER final com as Descrições




### 2. Análise Exploratória no Ambiente SQL (BigQuery)

Utilizando BigQuery para análise exploratória dos dados refinados, foram realizadas as seguintes operações:


#### 2.2a) Contagem de Registros

SELECT COUNT(\*) AS TotalRecords FROM `elated-drive-432523-s4.REFINED.WEATHER`;




#### 2.2b) Visualização de Amostra dos Dados (Primeiras Dez Linhas)

# SELECT \* FROM `elated-drive-432523-s4.REFINED.WEATHER`



#### 2.2c) Descrição dos Campos da Tabela


```
table_name
   ,column_name
   ,field_path
   ,data_type
   ,description
FROM `elated-drive-432523-s4.REFINED.INFORMATION_SCHEMA.COLUMN_FIELD_PATHS`
WHERE table_name = 'WEATHER'
;
```




#### 2.2d) Contagem de Valores Distintos

#### Exemplo

SELECT COUNT(DISTINCT SubprefectureName) AS DistinctSubprefectureNames FROM `elated-drive-432523-s4.REFINED.WEATHER`;



# Query results



## 2.2e) Estatísticas Descritivas (Média, Mínimo, Máximo)

Exemplo de cálculo para a coluna Temperature:

```
SELECT
    'TemperatureStats' AS Description,
    TO_JSON_STRING(t) AS Value
FROM (
    SELECT
     AVG(Temperature) AS AvgTemperature,
     MIN(Temperature) AS MinTemperature,
     MAX(Temperature) AS MaxTemperature
```

```
FROM `elated-drive-432523-s4.REFINED.WEATHER`
) t
UNION ALL
SELECT
    'WindSpeedStats' AS Description,
   TO_JSON_STRING(t) AS Value
FROM (
   SELECT
       AVG(WindSpeed) AS AvgWindSpeed,
       MIN(WindSpeed) AS MinWindSpeed,
       MAX(WindSpeed) AS MaxWindSpeed
   FROM `elated-drive-432523-s4.REFINED.WEATHER`
) t

    ExploratoryDataAnalysis-Weather

                                                                   SAVE QUERY ▼
   51 -- 2.2e) Descriptive Statistics (Mean, Min, Max)
52 -- This part calculates the mean, minimum, and maximum for numerical field
53 SELECT
        ··'TemperatureStats' AS Description,
··TO_JSON_STRING(t) AS Value
       FROM (
         SELECT
         - AVG(Temperature) - AS-AvgTemperature,
- MIN(Temperature) - AS-MinTemperature,
- MAX(Temperature) - AS-MaxTemperature
   59
   61
62
        FROM elated-drive-432523-s4.REFINED.WEATHER
       UNION-ALL
   64
65
         'WindSpeedStats' AS Description,
        ··TO_JSON_STRING(t) · AS · Value
   69
       FROM - (
        SELECT
          - AVG(WindSpeed) AS AvgWindSpeed, MIN(WindSpeed) AS MinWindSpeed,
         · · · MAX(WindSpeed) · AS · MaxWindSpeed
   Query results
   JOB INFORMATION
                           RESULTS
                                         CHART
                                                       JSON
                                                                   EXECUTION DETAILS
          Description -
                                       Value ▼
          WindSpeedStats
                                        {"AvgWindSpeed":1.90991725
                                        47042977, "MinWindSpeed": 0,"
                                        MaxWindSpeed":6.69}
          TemperatureStats
                                        {"AvgTemperature":297.14541
                                        66666759."MinTemperature":
                                        288.81,"MaxTemperature":307.
```

# 2.2f) Distribuição de Frequência

```
-- 2.2f) Frequency Distribution (Count of Elements for Each Field)
-- This part shows the frequency distribution of categorical fields.

SELECT
    'WeatherMainFrequency' AS Description,
    TO_JSON_STRING(t) AS Value

FROM (
    SELECT
    WeatherMain,
    COUNT(*) AS Frequency
FROM `elated-drive-432523-s4.REFINED.WEATHER`
```

```
GROUP BY WeatherMain
  ORDER BY Frequency DESC
UNION ALL
SELECT
   'SubprefectureNameFrequency' AS Description,
   TO_JSON_STRING(t) AS Value
FROM (
   SELECT
     SubprefectureName,
     COUNT(*) AS Frequency
   FROM `elated-drive-432523-s4.REFINED.WEATHER`
   GROUP BY SubprefectureName
   ORDER BY Frequency DESC
) t;

    ExploratoryDataAnalysis-Weather

                                                       C RUN
                                                                  SAVE QUERY ▼
                                                                                       ▼ DOWNLOAD
                                                                                                       +≗ SHARE ▼
       ---2.2f) Frequency Distribution (Count of Elements for Each Field)
       -- This part shows the frequency distribution of categorical fields.
   81
         'WeatherMainFrequency'-AS-Description,
        TO_JSON_STRING(t) AS Value
   82
   83
       FROM-
        SELECT
   84
         - WeatherMain,
- COUNT(*) AS Frequency
   85
   86
        FROM: elated-drive-432523-s4.REFINED.WEATHER
GROUP BY WeatherMain
   87
   88
        · ORDER · BY · Frequency · DESC
   89
   99
       ) · t
   91
       UNION-ALL
   92
   93
   94
       SELECT-
   95
         'SubprefectureNameFrequency' AS Description,
         TO_JSON_STRING(t) AS Value
   Query results
   JOB INFORMATION
                          RESULTS
                                         CHART
                                                      JSON
                                                                  EXECUTION DETAILS
                                                                                           EXECUTION GRAPH
          Description ▼
     1
         WeatherMainFrequency
                                       {"WeatherMain": "Clouds", "Frequency": 8420}
                                       {"WeatherMain": "Clear", "Frequency": 14360}
     2
         WeatherMainFrequency
     3
          WeatherMainFrequency
                                       {"WeatherMain":"Mist","Frequency":510}
     4
         WeatherMainFrequency
                                       {"WeatherMain":"Haze","Frequency":358}
     5
         WeatherMainFrequency
                                       {"WeatherMain":"Fog","Frequency":160}
         SubprefectureNameFrequency
                                       {"SubprefectureName": "Sé", "Frequency": 744}
     6
                                       {"SubprefectureName":"Lapa","Frequency":744}
         SubprefectureNameFrequency
         SubprefectureNameFrequency
                                       {"SubprefectureName":"Mooca","Frequency":744}
     9
          SubprefectureNameFrequency
                                       {"SubprefectureName": "Penha", "Frequency": 744}
    10
         SubprefectureNameFrequency
                                       {"SubprefectureName": "Perus", "Frequency": 744}
```

## 3. Documentação e Evidências

Todas as etapas foram capturadas e documentadas para comprovar o funcionamento do pipeline.

# Conclusão